



INSTITUTO SUPERIOR TECNOLÓGICO PARTICULAR SUDAMERICANO

Desarrollo de un Sistema de Análisis Estadístico con Python

StatLab - Aplicación de escritorio reutilizable

Asignatura Probabilidad y Procesos Estocásticos	Carrera Desarrollo de Software
Integrantes Alexis Patiño Carlos Zhuzhingo	Docente Ing. Nancy Eras

Ecuador - Julio de 2026

Índice general

1. Introducción	3
1.1 Problema abordado	3
2. Objetivos	3
2.1 Objetivo general	3
2.2 Objetivos específicos	3
3. Dataset utilizado	4
3.1 Variables principales	4
4. Arquitectura de la aplicación	5
4.1 Responsabilidades de los módulos	5
4.2 Flujo de procesamiento	5
5. Metodología estadística	6
5.1 Distribución de frecuencias	6
5.2 Criterios de interpretación	6
6. Funcionalidades implementadas	7
6.1 Diseño y usabilidad	7
7. Capturas de pantalla	8
8. Resultados e interpretación	12
8.1 Tendencia central y forma	12
8.2 Dispersión y atípicos	12
8.3 Comparaciones contextuales	13
Correlaciones lineales con Rented Bike Count	13
8.4 Variabilidad entre variables	13
9. Validación y pruebas	14
9.1 Manejo de errores	14
9.2 Limitaciones	14
10. Conclusiones	15
10.1 Recomendaciones	15
11. Bibliografía	16

1. Introducción

El análisis estadístico descriptivo transforma registros tabulares en información comprensible mediante medidas, distribuciones y gráficos. En proyectos de software, automatizar este proceso reduce cálculos repetitivos, mejora la trazabilidad y permite aplicar el mismo procedimiento a distintos conjuntos de datos.

Como respuesta al proyecto integrador de Probabilidad y Procesos Estocásticos, se desarrolló StatLab, una aplicación de escritorio en Python capaz de importar archivos CSV o Excel, identificar sus variables numéricas y generar un análisis descriptivo completo sin modificar el código fuente. El sistema separa la carga, los cálculos, los gráficos, la interpretación y la exportación en módulos independientes.

1.1 Problema abordado

Calcular manualmente tablas de frecuencia y medidas para cada variable consume tiempo y aumenta el riesgo de errores de transcripción. Además, los resultados numéricos aislados no siempre explican la forma, dispersión o presencia de valores atípicos. StatLab integra cálculo, visualización e interpretación en un flujo único y verificable.

Alcance

La aplicación realiza análisis descriptivo. No pretende demostrar causalidad ni sustituir el criterio del analista sobre la calidad y procedencia de los datos.

2. Objetivos

2.1 Objetivo general

Diseñar e implementar una aplicación de escritorio reutilizable en Python que automatice el análisis estadístico descriptivo de conjuntos de datos tabulares y comunique los resultados mediante tablas, gráficos e interpretaciones contextualizadas.

2.2 Objetivos específicos

- Importar y validar archivos CSV y Excel (.xlsx).
- Detectar automáticamente las variables numéricas disponibles.
- Calcular distribuciones de frecuencia y medidas de tendencia central y dispersión.
- Generar representaciones gráficas con títulos, ejes y escalas legibles.
- Detectar atípicos e interpretar el comportamiento de la variable seleccionada.
- Organizar el código en módulos reutilizables, documentados y probados.
- Permitir la exportación de resultados a CSV y PDF.

3. Dataset utilizado

Para demostrar el sistema se utilizó Seoul Bike Sharing Demand, publicado por UCI Machine Learning Repository. El archivo contiene el número de bicicletas alquiladas por hora en el sistema público de Seúl y variables meteorológicas relacionadas. UCI informa 8.760 instancias, variables enteras y reales, y ausencia de valores faltantes. El recurso se distribuye con licencia CC BY 4.0 y DOI 10.24432/C5F62R.

Propiedad	Valor
Registros	8.760
Columnas del archivo	14
Variables numéricas	10
Variables no numéricas	4
Periodo	Diciembre de 2017 a noviembre de 2018
Valores faltantes	0
Fuente	UCI Machine Learning Repository
Licencia	Creative Commons Attribution 4.0

3.1 Variables principales

Variable	Tipo	Descripción
Rented Bike Count	Entera	Bicicletas alquiladas por hora.
Hour	Entera	Hora del día, de 0 a 23.
Temperature_C	Continua	Temperatura del aire en grados Celsius.
Humidity_pct	Entera	Humedad relativa en porcentaje.
Wind speed_m_s	Continua	Velocidad del viento en m/s.
Visibility_10m	Entera	Visibilidad medida en unidades de 10 m.
Solar Radiation_MJ_m2	Continua	Radiación solar en MJ/m2.
Rainfall_mm / Snowfall_cm	Continua	Precipitación de lluvia y nieve.
Seasons / Holiday	Categórica	Estación y condición de feriado.
Functioning Day	Categórica	Indica si el sistema operó.


Consideración de entrega

El dataset debe ser aprobado por el docente para confirmar que no haya sido registrado por otro grupo. Si se cambia, StatLab lo analizará sin cambios de código.

4. Arquitectura de la aplicación

La solución sigue una arquitectura modular. La interfaz coordina las acciones del usuario, mientras que cada responsabilidad estadística permanece en un archivo independiente. Esta separación facilita pruebas, mantenimiento y reutilización.

Flujo modular de StatLab



Entrada: CSV/XLSX | Salida: métricas, tablas, gráficos, interpretación y PDF

4.1 Responsabilidades de los módulos

Módulo	Responsabilidad
data_loader.py	Carga CSV/XLSX, codificaciones, validación y perfil general.
statistics_engine.py	Frecuencias, medidas, cuartiles, atípicos y ranking de CV.
visualizations.py	Histograma, barras, polígono, curva acumulada y boxplot.
interpretation.py	Explicaciones automáticas prudentes y comparación de variables.
reporting.py	Exportación del análisis seleccionado a PDF.
ui.py	Interfaz, navegación, selección de variable y coordinación del flujo.

4.2 Flujo de procesamiento

El usuario selecciona un archivo; el cargador valida formato y contenido; la interfaz obtiene el perfil y lista las columnas numéricas; el motor limpia temporalmente nulos o infinitos de la variable seleccionada; luego calcula métricas y frecuencias. Finalmente se actualizan tablas, gráficos, texto interpretativo y opciones de exportación.

5. Metodología estadística

Los cálculos se realizan sobre los valores numéricos válidos de la variable. No se modifican los registros originales. La varianza principal se presenta como poblacional porque se describe la totalidad del archivo cargado; también se ofrece la versión muestral para otros contextos.

Indicador	Expresión aplicada	Interpretación
Media	$\text{suma}(xi) / n$	Centro aritmético.
Mediana	Percentil 50	Centro resistente a extremos.
Moda	Valor con mayor frecuencia	Valor más repetido.
Rango	máximo - mínimo	Amplitud total.
Desviación media	$\text{promedio}(xi - \text{media})$	Distancia absoluta media.
Varianza poblacional	$\text{suma}((xi - \text{media})^2) / n$	Dispersión cuadrática.
Desviación estándar	$\text{raíz}(\text{varianza})$	Dispersión en unidades originales.
CV	$\text{desv. estándar} / \text{media} \times 100$	Variabilidad relativa.
Atípicos	$< Q1 - 1,5 \text{ RIC} \text{ o } > Q3 + 1,5 \text{ RIC}$	Observaciones alejadas.

5.1 Distribución de frecuencias

Para variables con hasta 15 valores distintos, cada valor constituye una clase. Para variables continuas se aplica la regla de Sturges ($k = 1 + 3,322 \log_{10}(n)$), con un límite práctico de 5 a 20 intervalos para mantener la legibilidad. Se calculan frecuencia absoluta, relativa, porcentual y acumulada.

5.2 Criterios de interpretación

El coeficiente de variación se clasifica de forma orientativa como bajo (menor a 15 %), moderado (15 % a menos de 30 %) o alto (30 % o más). La asimetría se interpreta junto con la comparación media-mediana y los gráficos. Estas reglas sirven como apoyo descriptivo, no como decisiones automáticas definitivas.

6. Funcionalidades implementadas

Funcionalidad	Implementación y validación
Carga y visualización	CSV/XLSX, detección de codificación, tabla de hasta 500 filas.
Perfil del dataset	Filas, columnas, tipos, nulos, duplicados y memoria.
Frecuencias	Tabla dinámica por valor o por intervalos de Sturges.
Tendencia central	Media, mediana y moda con explicación automática.
Dispersión	Rango, desviación media, varianzas, desviaciones y CV.
Gráficos	Histograma, barras, polígono, curva acumulada y boxplot.
Atípicos	Detección mediante 1,5 RIC y reporte de límites.
Interpretación	Centro, dispersión, forma, atípicos y comparación de CV.
Exportación	Frecuencias a CSV y reporte individual a PDF.
Manejo de errores	Formato, archivo vacío, columnas duplicadas y falta de numéricas.

6.1 Diseño y usabilidad

La interfaz agrupa el flujo en cinco pestañas: Resumen, Datos, Frecuencias, Gráficos e Interpretación. La fuente de datos y la selección de variable permanecen visibles en la barra lateral, de modo que todas las vistas se actualizan de forma coherente. La paleta oscura, los acentos azules, las tarjetas de indicadores y las tablas con encabezados contrastados mantienen una jerarquía visual uniforme.

Funcionalidad adicional

Además de los mínimos solicitados, se incluyen boxplot, cuartiles, rango intercuartílico, asimetría, curtosis, coeficiente de variación, ranking comparativo y exportación de reportes.

7. Capturas de pantalla

Las siguientes capturas muestran la ejecución con el dataset de demostración y la variable Rented Bike Count.




Figura 1. Resumen del dataset y métricas de la variable seleccionada.




Figura 2. Tabla de frecuencias agrupada automáticamente mediante Sturges.



Figura 3. Histograma, barras, polígono y curva de frecuencia acumulada.




Figura 4. Interpretación automática del comportamiento estadístico.

8. Resultados e interpretación

La variable principal representa la demanda horaria de bicicletas. Los resultados calculados por StatLab son los siguientes:

Indicador	Resultado
Datos válidos	8,760
Mínimo / máximo	0.00 / 3556.00
Media	704.60
Mediana	504.50
Moda	0
Rango	3556.00
Desviación media	520.08
Varianza poblacional	415974.24
Desviación estándar	644.96
Coefficiente de variación	91.54 %
Asimetría	1.15
Atípicos por 1,5 RIC	158

8.1 Tendencia central y forma

La media es 704.60 bicicletas por hora y la mediana 504.50. Como la media supera ampliamente a la mediana y la asimetría es 1.15, la distribución presenta una cola hacia la derecha. El histograma confirma que la mayor concentración se encuentra en los intervalos bajos, mientras una proporción menor alcanza valores altos.

La moda igual a 0 debe interpretarse con el contexto operativo. El dataset incluye 295 horas marcadas como días no funcionales y en todas ellas el conteo es cero; por ello, el cero no representa necesariamente ausencia espontánea de demanda.

8.2 Dispersión y atípicos

La desviación estándar es 644.96 y el coeficiente de variación 91.54 %, por lo que la demanda es heterogénea. Se detectaron 158 valores atípicos mediante el criterio de 1,5 RIC. No deben eliminarse automáticamente: pueden corresponder a horas reales de demanda excepcional.

Conclusión del indicador principal

El promedio por sí solo no resume adecuadamente la demanda. La mediana, la dispersión y la forma de la distribución deben presentarse en conjunto.

8.3 Comparaciones contextuales

La media estacional más alta corresponde a verano y la más baja a invierno. Esta comparación es descriptiva; no separa el efecto de temperatura, horas de luz, feriados u otras variables.

Estación	n	Media	Mediana	Desv. estándar
Autumn	2,184	819.60	763.50	651.09
Spring	2,208	730.03	583.00	621.51
Summer	2,208	1034.07	905.50	690.24
Winter	2,160	225.54	203.00	150.37

Correlaciones lineales con Rented Bike Count

Variable	Correlación de Pearson
Temperature_C	0.539
Hour	0.410
Dew point temperature_C	0.380
Solar Radiation_MJ_m2	0.262
Visibility_10m	0.199
Wind speed_m_s	0.121
Rainfall_mm	-0.123
Snowfall_cm	-0.142
Humidity_pct	-0.200

La temperatura muestra la asociación positiva más alta ($r = 0.539$); la humedad presenta una asociación negativa débil ($r = -0.200$). Correlación no implica causalidad y las relaciones podrían no ser lineales.

8.4 Variabilidad entre variables

Variable	Media	Desv. estándar	CV (%)
Rainfall_mm	0.149	1.128	758.73
Snowfall_cm	0.075	0.437	581.76
Dew point temperature_C	4.074	13.060	320.57
Solar Radiation_MJ_m2	0.569	0.869	152.64
Temperature_C	12.883	11.944	92.71
Rented Bike Count	704.602	644.961	91.54

Lluvia y nieve tienen los CV más altos porque sus medias son muy pequeñas y contienen muchos ceros. Esto demuestra por qué el CV debe interpretarse con cautela cuando el promedio se aproxima a cero.

9. Validación y pruebas

El motor se verificó con pruebas unitarias y con el dataset real. Las pruebas comparan media, mediana, moda, varianza, desviación estándar y desviación media contra resultados de referencia; también verifican que las frecuencias sumen n , que las relativas sumen 1 y que las porcentuales sumen 100.

Prueba	Criterio	Resultado
Carga CSV	8.760 filas y 14 columnas	Aprobada
Requisitos mínimos	≥ 300 filas, ≥ 5 columnas, ≥ 3 numéricas	Aprobada
Tendencia central	Coincide con pandas	Aprobada
Dispersión	Coincide con fórmulas poblacionales	Aprobada
Frecuencias	Suma $f=n$, suma $fr=1$, suma $\%=100$	Aprobada
Atípicos	Criterio $Q1/Q3$ y 1,5 RIC	Aprobada
Variable constante	Rango y desviación iguales a 0	Aprobada
Generación PDF	Archivo legible con resultados y gráficos	Aprobada

9.1 Manejo de errores

La aplicación informa si el archivo no existe, está vacío, tiene un formato no admitido, contiene nombres de columnas duplicados o no posee variables numéricas. Para CSV prueba codificaciones UTF-8, CP1252 y Latin-1 y detecta el separador. Los valores no numéricos no se fuerzan salvo que al menos el 95 % de una columna de texto sea convertible.

9.2 Limitaciones

Las interpretaciones automáticas usan reglas generales y no conocen todas las particularidades del dominio. Los umbrales de variabilidad son orientativos. La vista previa limita la tabla a 500 registros para conservar fluidez, aunque los cálculos utilizan todo el dataset.

10. Conclusiones

StatLab cumple el objetivo de analizar datasets tabulares sin codificar nombres ni valores específicos. La arquitectura modular permite reemplazar el dataset de demostración y conservar el mismo flujo de trabajo.

El sistema integra las medidas solicitadas, las cuatro representaciones gráficas obligatorias y una interpretación que relaciona centro, dispersión, asimetría y atípicos. Las funciones adicionales - boxplot, CV, cuartiles, curtosis, ranking y exportación - enriquecen la experiencia del usuario.

En el caso estudiado, la demanda de bicicletas es asimétrica y altamente variable. La media es mayor que la mediana, existen 158 atípicos y el verano presenta el promedio estacional más alto. Los resultados ilustran que una decisión informada requiere combinar métricas y gráficos.

10.1 Recomendaciones

- Conservar junto con la entrega la referencia y la aprobación del dataset.
- Realizar la demostración en el mismo equipo que se usará para la sustentación.
- No eliminar atípicos sin revisar su significado operativo.
- Como trabajo futuro, incorporar filtros por categoría y análisis bivariado interactivo.

11. Bibliografía

Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. Computing in Science & Engineering, 9(3), 90-95. <https://doi.org/10.1109/MCSE.2007.55>

McKinney, W. (2010). Data structures for statistical computing in Python. En Proceedings of the 9th Python in Science Conference (pp. 56-61). <https://doi.org/10.25080/Majora-92bf1922-00a>

Python Software Foundation. (2026). Python 3 documentation. <https://docs.python.org/3/>

Seoul Bike Sharing Demand [Dataset]. (2020). UCI Machine Learning Repository. <https://doi.org/10.24432/C5F62R>

The pandas development team. (2026). pandas documentation. <https://pandas.pydata.org/docs/>

Tukey, J. W. (1977). Exploratory data analysis. Addison-Wesley.

Declaración de reproducibilidad

El código fuente, el dataset, las pruebas y el generador de este informe se entregan juntos. Los indicadores del capítulo 8 se recalculan desde el CSV cada vez que se ejecuta `generar_informe.py`.